六人阿瓦隆中显式交流的作用

Silent Avalon Research Project Specification

CS7329 Reinforcement Learning ｜ 项目规划 v2（结构化通信） ｜ 2026 年 10 月 20 日

1 项目概述

本项目研究六人隐藏身份游戏《阿瓦隆》中，移除显式交流如何改变阵营胜率、策略行为及信息传递。固定角色为两名平民、莫甘娜、刺客、梅林和派西维尔。研究采用同一套游戏规则与强化学习算法，分别训练可通信智能体与 Silent Avalon 智能体，并加入训练后禁言实验，区分渠道移除的即时影响与长期策略适应。

建议的核心方案是小型 recurrent PPO 多智能体训练，加上五槽结构化消息协议：身份声明、阵营判断、判断依据、组队建议、行动倾向。每个槽位都有独立开关，因此“交流”可以被拆成可单独移除的信息类型，而不只是整体开或关。自然语言交流作为独立扩展实验，并复用同一套五槽结构。核心实验保留“显式交流对比沉默”的因果问题，能够利用本地 RTX 5070 Ti Laptop 完成开发和试验，并把学校 HPC 用于多随机种子训练。9B 模型不承担核心实验的端到端强化学习训练。

范围界定：五槽消息是对线下一次约 2 分钟、约 400 tokens 发言的结构化抽象。它覆盖这类发言的主要信息类型，但不包含措辞、语气、即兴追问和长篇推理，不能等同于开放式语言讨论。核心结论只适用于所定义的槽位、取值范围、角色配置和训练所得策略。若最终论文要直接声称“自然语言被移除后的效果”，必须补充自然语言实验，并单独报告其结果。

研究问题

问题	需要回答的内容	主要证据
RQ1 Game Balance	禁言后，哪一阵营更容易获胜？	好人最终胜率、三次任务成功概率、条件刺杀成功率
RQ2 Strategic Behavior	组队、投票、破坏与身份隐藏如何调整？	按角色和局面分层的行为指标及训练轨迹
RQ3 Implicit Signaling	公开行为是否承担信息传递功能？	信息增益、接收者干预、跨种子和跨搭档验证
RQ4 Message Components	五类显式信息中，哪些是通信效果的主要来源？	槽位开关的训练时与测试时消融、槽位使用率与真实性、听者因果影响

不预设沉默一定有利于坏人。交流可能帮助好人协调，也可能帮助坏人欺骗或识别梅林；任务阶段与刺杀阶段的效果还可能相互抵消。不同槽位的作用方向也可能相反，例如身份声明可能帮助派西维尔，也可能

把梅林暴露给刺客。RQ1、RQ2 为核心研究目标；RQ4 至少完成“最小通信”与“完整通信”两档对照及测试时槽位消融；RQ3 为有明确证据标准的探索目标。即使没有显著胜率变化，或没有发现稳定信号，也可以形成有效结果。

2 文献定位与课程关联

DeepRole 研究五人阿瓦隆，明确不使用自然语言交流，以推断、搜索和学习的价值函数处理合作与对抗。[1] 因而“阿瓦隆可以在沉默条件下由智能体完成”已有先例；本项目应研究同一训练框架下通信条件变化带来的差异，而不是把 Silent Avalon 本身作为首次提出的环境。

Is it Percival time yet 是 SIGBOVIK 2017 的初步人类游戏分析，报告 66 局采集、剔除 5 局后的 61 局数据。[2] 它可帮助提出刺杀、身份暴露和破坏协调的指标，但样本与角色配置存在限制，不足以直接推导禁言的因果效应。

STRATEGIST 使用 LLM 生成和改进策略，并结合低层搜索进行决策，不能直接视为 PPO 式参数训练。[3] 尤其需要注意，附录 O 已描述六人局有对话与无对话的人类实验，但其角色为 Merlin、三名 Servants、Minion 与 Assassin，不含 Percival 与 Morgana，并且是 LLM 智能体与人类对局，不是受控训练。因此本项目的拟贡献是可复现的训练对照、策略适应分析及信号机制检验；单纯“六人局加禁言对照”不足以确立创新性。该文正文与附录的人类实验总局数表述不同，本文不把其汇总胜率当作可直接比较的基准。

AvalonBench 及其代码库可作为环境实现的候选起点。[4,10] Lan 等人的六人 Avalon 研究采用包含 Percival 与 Morgana 的角色配置，并分析了协调、伪装和信息分享等行为，可用于借鉴行为分类。[5] 即使角色构成相同，具体规则、语言模型和实验规模仍须逐项核对，不应直接与本项目胜率拼成排行榜。

结构化通信的先例与风险。把消息当作策略的离散动作、与其他动作一起用强化学习训练，可追溯到 Foerster 等人的 RIAL；本项目沿用这一思路，只是用 PPO 代替 DQN，并把一条消息拆成五个槽位。[16] RLupus 在狼人杀中用 PPO 训练村民的离散通信信道（狼人为规则策略），九人局村民胜率从无通信的 0.044 最高提到 0.45，而且信号长度与取值范围对性能的影响是非线性的。[11] CICERO 先由规划模块产生 intent，再由受控对话模型把 intent 转成语言。[12] 本项目的五槽消息与这种 intent 思路一致：RL 决定“说什么”，语言层只负责“怎么说”。Cao 等人发现，自利智能体难以利用没有内在含义的 cheap-talk 信道，合作型智能体则可以。[13] 阿瓦隆阵营内部合作、阵营之间对抗，而且坏人可以模仿任何消息，所以通信是否被学会需要单独诊断，不能只看槽位名称。

拟贡献：提供一个在规则、算法和预算上受控的通信消融实验；用可独立开关的五槽协议把“交流”分解为可单独移除的信息类型；把整体胜负分解为任务与刺杀两条路径；通过行为干预区分“动作包含信息”与“动作被用来影响其他智能体”。这是一项实验研究与机制分析项目，不以提出新的 RL 优化算法为必要条件。

与课程内容的连接

课程中的 MDP 在这里扩展为 Partially Observable Stochastic Game。完整局面包括隐藏身份，单个玩家只能访问自己的 observation history。Actor 学习策略 π，critic 学习该玩家信息条件下的价值 V；终局胜负提供 return，TD 与 GAE 用于估计 advantage，PPO 用于更新策略。[7,8] Self-play 则使其他玩家的策略也随训练变化。

课程项目要求动机与 RL 关联、相关研究、技术方法、文献或自有实验结果，以及局限性讨论。[C1] 本方案覆盖这些内容，并与仓库中的部分可观察性、函数近似、Actor–Critic 和 PPO 教学材料衔接。[C2]

3 环境规则与信息边界

核心六人配置

主实验固定为两名平民（Loyal Servants）、一名莫甘娜（Morgana）、一名刺客（Assassin）、一名梅林（Merlin）和一名派西维尔（Percival）。好人阵营为梅林、派西维尔及两名平民，坏人阵营为莫甘娜与刺客。可通信、沉默及训练后禁言条件均采用这一配置；派西维尔与莫甘娜的身份辨别及混淆机制属于核心研究范围。

项目	固定规范
任务与表决	五轮任务人数为 2、3、4、3、4；至少四票赞成才通过，平票否决。同一任务连续五次提案被否决，坏人获胜。
任务执行	好人只能提交 Success；坏人可选 Success 或 Fail。六人局每轮一张 Fail 即失败。公开失败票总数，不公开个人任务票。
终局判定	三次任务失败即坏人胜；三次成功后由 Assassin 刺杀，命中 Merlin 则坏人胜，否则好人胜。
身份信息	所有人知道自己的角色。Merlin 知道两名坏人的座位，但不知道 Percival 的位置；Percival 看到 Merlin 与 Morgana 的两名候选者，但不知道谁是谁；Morgana 与 Assassin 互认坏人队友；两名平民没有额外身份信息。
随机化	每局随机分配角色和初始队长，随后队长按规则轮换；禁用 Lady of the Lake 等附加机制。

上述规则以游戏规则书为基准。[9] 座位编号不能固定对应角色；Percival 的两名候选者使用无身份标签的集合表示，不能用排列顺序泄露谁是 Merlin。投票与任务牌必须先分别提交、再一起揭示，防止执行顺序泄露未公开选择。仿真器完整状态仅用于裁判和离线分析。

结构化通信协议

发言时机：每次队长公布提案后、全员投票前有一轮公开讨论。从队长开始按座位顺序，六名玩家各发一条结构化消息，后发言者可以看到先发言者的内容；队长先发言，相当于说明组队理由。三次任务成功后

进入刺杀阶段，两名坏人各有一次公开发言，只开放阵营判断槽，含义改为“我认为 j 是梅林”。每次提案只有一轮发言，比 v1 的提案前、提案后两轮少一半通信决策，以缩短每名玩家的决策序列。

每条消息最多包含五个槽位，对应线下一次约 2 分钟发言的五类内容。所有取值都是离散的，均由策略选择；允许虚假内容，裁判只检查合法性，不检查真假。

槽位	线下对应	离散取值	约束
① 身份声明	我是谁、我自称什么角色	不声明、忠臣、派西维尔、梅林	允许虚假声明；可在不同轮次改口，历次声明公开可见
② 阵营判断	我认为谁好谁坏	对其余五名玩家各选：不评、好、坏	允许虚假判断；刺杀阶段改为标记梅林候选
③ 判断依据	我为什么这样判断	对每名被评为好或坏的玩家选一条依据：任务记录、投票记录、组队记录（各附所指轮次）、身份视野声明，或无依据	依附于 ②；公开记录类依据只能指向真实发生的事件，但可以选择性引用；身份视野声明不可验证
④ 组队建议	我点哪些人上车	不建议，或当前任务人数下的任一合法队伍（最多 20 种）	使用与队长提案动作相同的队伍编码；队长此槽固定为其提案
⑤ 行动倾向	我赞成或反对，希望谁回应	投票倾向：不表态、赞成、反对；点名：无，或本轮尚未发言的玩家	倾向不约束实际投票；被点名者发言时可见点名记录

开关与“不说”：每个槽位有独立开关。开启的槽位都包含“不说”选项，所以五句话中的任何一句都可以不说；关闭的槽位固定为“不说”，不进入策略的动作损失。③ 依附于 ②，开启 ③ 时必须开启 ②；①、④、⑤ 与其他槽位相互独立。

判断依据的约束：公开记录类依据只能引用确有其事的事件，由合法动作掩码保证。理由有二：线下歪曲公开记录会被当场识破；把可验证的公开依据与不可验证的身份视野声明分开，便于检验“有依据的指控”是否更能影响听者。若 pilot 发现该约束使 ③ 几乎不被使用，可把“允许虚假引用”作为事先说明的变体，单独报告。

渲染与记录：每条消息以槽位元组形式存储，并用固定模板渲染成中文或英文句子，供日志阅读和自然语言扩展使用。例如：“我是派西维尔。我认为 3 号是坏人，因为第 2 轮任务失败时他在队里。我建议 1、2、5 号上车。我反对当前队伍，请 4 号回应。”完整五槽消息渲染后约为数十到一百余 tokens，低于 400 tokens 的线下发言上限；差额对应措辞、语气和冗余，不属于核心实验。

Silent Avalon 关闭全部五个槽位并跳过讨论阶段，对智能体而言等价于每名玩家每个槽位都选择“不说”。公开的队伍、已揭示投票、任务结果和失败票数仍然可见。训练后禁言同样实现为强制所有槽位“不说”，而不是引入训练中从未出现的新 NULL 符号，以减轻分布外输入效应。所有条件都禁止私聊、跨玩家共享记忆及利用延迟、报错等额外信道。

通信配置与消融

配置	身份	判断	依据	组队	倾向	用途
S	关	关	关	关	关	沉默基线
M	关	开	开	关	关	最小通信：只说谁好谁坏、为什么
F	开	开	开	开	开	完整结构化通信
F−Claim	关	开	开	开	开	留一消融：身份声明
F−Team	开	开	开	关	开	留一消融：组队建议
F−Intent	开	开	开	开	关	留一消融：行动倾向
J（可选）	关	开	关	关	关	判断依据的边际作用

核心层为 S、M、F 三个训练配置；扩展层为三个留一配置。② 与 ③ 在 M 与 F 系列中总是同时出现，若不训练可选的 J 配置，就无法单独识别“判断依据”在训练适应后的作用；至少应在 M 的冻结 checkpoint 上做一次关闭 ③ 的测试时消融。各配置使用相同的网络结构、输出头、发言顺序和训练预算，只通过掩码改变可用槽位。

这种通信安排是有带宽限制的实验协议。记录槽位定义、取值范围、发言顺序和机会数并保持不变；不能把结果直接推广到任意长度、任意时间的自由讨论。给槽位和取值起了自然语言名称，也不代表智能体学到的含义一定与名称相同；含义需要用第 6 节的真实性与听者影响指标实测。

4 强化学习方法

策略与价值网络

采用 recurrent Independent PPO 作为首选基线：好人与坏人各使用一套小型 MLP + GRU actor–critic，同阵营共享参数，输入包含自身角色和其合法私有信息。每个玩家独立维护 recurrent hidden state；共享网络权重不意味着共享其他玩家的记忆。先使用 128 维编码与 128 维 GRU 作为试验配置，并在正式比较前冻结架构。

输入为公共游戏历史、自身历史行动、角色允许的信息及通信记录；通信记录按槽位编码，并区分“槽位关闭”与“选择不说”。输出使用分阶段 action heads：队长选择合法队伍，全员选择赞成或反对，坏人选择任务牌，Assassin 选择刺杀目标。采用 legal action mask 排除非法动作。六人局合法队伍最多 20 种，可直接枚举，无须生成任意文本动作。

消息输出头：讨论阶段为五个槽位分别设输出头。① 是一个 4 类头；② 是五个按玩家分解的 3 类头；③ 对每名被评为好或坏的玩家设一个依据类型头和一个轮次头，由掩码保证只能选真实事件；④ 与队长提案共享队伍编码；⑤ 是投票倾向头加点名头。一条消息的对数概率等于已开启子动作对数概率之和，

PPO 比率按这一联合概率计算。所有配置保留全部输出头，关闭的槽位只通过掩码移除，以保证各配置网络容量一致。消息头与行动头共享参数和编码器，属于 RIAL 式训练；不采用让梯度穿过信道的 DIAL，因为阿瓦隆的听者中有对手。[16]

选择 recurrent policy 是为了利用历史信息，而非把当前观察错误地当成完整 Markov state。核心 critic 同样只接收该玩家可获得的信息；若日后采用 centralized critic，必须单独说明训练时的特权信息，且保证执行 actor 看不到它。

奖励与更新

每个玩家在己方最终获胜时得到 +1、失败时得到 −1，中间奖励为 0；以有限回合未折扣终局收益为目标，取 $\gamma = 1$，避免新增通信步骤改变同一胜负的折扣权重。两阵营分别汇总损失，避免四名好人相对两名坏人造成隐含的训练权重差异。

学习循环为：按当前策略采集完整对局 → 按玩家整理观察、合法动作、奖励和记忆序列 → 用价值估计与 GAE 计算 advantage → 用 PPO 更新行动头、消息头及 critic → 保存 checkpoint 并重复。通信动作也通过终局奖励学习。关闭槽位、强制“不说”和其他强制动作不计入 actor 的可选动作损失；padding 不参与梯度。

核心实验不增加“诚实发言”“成功传信”或“隐瞒身份”的额外奖励，避免把希望发现的策略直接写入奖励。是否出现信息交换和隐藏行为，由胜负激励下的学习结果决定。PPO、GAE 的具体超参数先在独立 pilot 中确定，之后各通信配置共用；不能按测试胜率分别挑选最有利参数。

通信学习诊断

结构化本身不能保证通信被学会。任何 cheap-talk 博弈都存在“说话者随意发言、听者完全忽略”的均衡，独立学习者容易停在这里。[13] 结构化的作用是缩小组合空间、让组队建议与提案共享编码、让依据锚定在真实事件上，并使分析可以逐槽进行。为此设置三项检查：

1. **玩具检查：**把坏人固定为规则策略，只训练好人在 M 配置下通信。若梅林的阵营判断仍不能提高好人胜率，优先排查实现错误，而不是得出“交流无用”的结论。
2. **发送端诊断：**计算各槽取值与发言者真实身份、被评价者真实阵营之间的互信息，按角色分层。
3. **接收端诊断：**在冻结 checkpoint 上替换某条消息中的某个槽位，测量听者投票与组队分布的 KL 变化，即 causal influence。[6,14]

第二阶段结束时，若 M 与 F 的接收端影响接近零，按第 9 节的检查点处理，不直接进入正式训练。可选的初始化办法是：先用“诚实规则发言者”的行为克隆初始化消息头，再用 RL 微调，使槽位名称在训练初期与其含义一致；之后是否转向欺骗由胜负奖励决定。若采用，所有通信配置统一使用，并在论文中报告。

Self play 与非平稳性

先训练两个阵营的当前策略，再维护历史 checkpoint 池，减少只适应最新对手的循环。建议 pilot 尝试每局以 50% 概率使用当前对手、25% 使用历史对手、25% 使用固定规则对手；正式实验锁定混合比例。对手的固定轨迹不参与当前策略的 on-policy 更新，同局队友仍保持独立观察。

保留随机合法策略和固定规则策略作 sanity baselines。规则策略只利用合法信息，例如根据任务失败记录累计嫌疑、坏人以固定概率破坏、刺客按简单公开行为评分猜 Merlin。它们用于检查学习是否改善，不能代表人类或最优策略。IPPO 在此环境的有效性需要试验确认，不能由其在合作基准上的表现直接推断。[7]

5 实验矩阵与统计计划

实验	训练配置	评估配置	解释
F → F	完整通信	完整通信	主 baseline
M → M	最小通信	最小通信	只保留阵营判断与判断依据
S → S	沉默	沉默	适应沉默后的策略表现
F → S M → S	F 或 M	冻结权重后全部槽位强制“不说”	立即失去通信渠道的影响
F → F−k	完整通信	冻结权重后关闭槽位 k	测试时槽位依赖，k 取身份、依据、组队、倾向
F−k → F−k	留一配置	同一留一配置	训练时留一消融（扩展层）
S → S mask	沉默	削弱指定历史线索	RQ3 的接收者依赖分析

主比较为 S → S 与 F → F，衡量完整显式交流的作用；M → M 与 S → S 的差衡量“谁好谁坏、为什么”这一最小通信的作用；F → F 与 M → M 的差衡量身份声明、组队建议和行动倾向的合计增量。F → S 与 F → F−k 使用与 F → F 完全相同的 checkpoint 和评估初始条件，只改变可用槽位。它们度量通信依赖，可能包含分布外输入效应，不等价于重新学会在缺少该槽位时游戏；测试时消融与训练时留一消融的差，才对应策略适应。

训练预算：先完成每个配置 2,000 局的功能与吞吐 pilot；依据耗时和学习曲线，在每次独立训练 20,000–100,000 局的候选范围内选择固定预算 B。该范围是规划参数，不是已验证的收敛需求。核心层 S、M、F 每个配置 3 个独立随机种子，共 9 次训练，资源允许再增至每配置 5 个；扩展层三个留一配置各 3 个种子，再加 9 次训练；可选 J 配置最后考虑。种子少于 3 个的配置只作描述性报告。

各配置匹配对局数、网络容量、PPO 更新次数与超参数，报告有效决策数、消息动作数和实际训练耗时。开启的槽位越多，消息子动作越多，各配置的信息和动作预算本来就不同；匹配对局数不等于完全匹配计算量。因此同时给出性能对训练局数及实际时间的曲线。

评估预算：每个训练种子在其对应的全部评估条件下各冻结评估 1,000 局。核心层每组种子约 10 个评估条件，即 S → S；M → M、M → S、M 关闭 ③；F → F、F → S 及四个 F → F−k，三个种子合计约 3 万局。配对使用相同角色分配和初始队长表，策略采样使用独立随机流；没有训练更新或跨局记忆。训练种子是主要重复单位，不能把评估局数当成同样数量的独立训练模型。

统计报告：先报告每个种子的指标，再汇总配对差值、效应量和 95% 区间。主结果使用按训练种子配对的分层 bootstrap，局内重复事件按完整游戏归组；种子数较少时明确区间不稳定。固定模型的单项胜率可另给 Wilson 区间，但不能用它替代训练不确定性。预先把好人最终胜率设为主指标，其余为机制与探索指标。

同训练群体 self-play 只能说明该群体下的经验平衡。增加不同训练种子的好人和坏人交叉对战，以及与固定对手池的评估，以区分策略强弱、共同适应和通信效果。对阵双方都使用被测环境规则，且分别汇报每一阵营的表现。

6 指标与可解释的结果

RQ1 游戏平衡

核心指标为 ΔGood = P(Good wins | S → S) − P(Good wins | F → F)。正值表示该实验设定下沉默更有利于好人，负值更有利于坏人。同样报告 S → S 相对 M → M 的差，以及 M → M 相对 F → F 的差。50% 只是阵营胜率对称的参考点，不意味着这款非对称游戏必须天然公平。

为解释总胜率，分解为 P(Good wins) = P(达到三次任务成功) × [1 − P(刺杀命中 Merlin | 达到三次任务成功)]。同时报告三次任务失败和连续五次否决导致的坏人获胜比例。刺杀成功率的分母只能是实际进入刺杀阶段的对局。

任务成功率按任务序号报告，分母为实际执行该轮任务的次数，并报告到达该轮的局数；不能把未发生的后续任务记作失败。刺杀条件样本很少时报告宽区间，必要时按预先规定对所有条件等量增加评估。已知两名坏人位置时，在四名好人中均匀随机猜 Merlin 的命中率是 25%，可作刺杀参考基线。

RQ2 策略行为

行为	建议量化方式	解释限制
组队与投票	提议及通过队伍的好人比例；不同角色的赞成率；对含坏人队伍的赞成率	按轮次、队伍人数、否决次数分层；最后机会的赞成不一定是判断错误

行为	建议量化方式	解释限制
任务破坏	坏人在队时的 Fail 率；双坏人在队时零张、一张、两张 Fail 的分布	放过任务可能用于伪装，两次破坏也不能自动判为协调失败
梅林隐藏	仅用公开历史训练身份 probe，评估识别 Merlin 的 log loss；结合任务与终局收益	probe 难以识别不等于实际刺客一定被欺骗
辨别与混淆	Percival 对两名候选者的组队和投票偏好；Morgana 对这些偏好的影响	控制局面与候选者历史；被支持不能直接等同于被认作 Merlin
刺客推断	条件刺杀准确率；对历史投票或组队记录的消融敏感度	控制进入刺杀阶段的样本选择差异

角色真值只在离线分析中用于计算这些指标。行为比较须覆盖早期、中期、最终 checkpoint；选取案例时使用明确抽样规则，同时展示支持与不支持假设的对局，不只挑选有趣的成功案例。

RQ4 消息组件

分析	建议量化方式	解释限制
槽位使用	各槽选择“不说”的比例随训练的变化，按角色、阵营和轮次分层	使用率高不等于有用；可能只是无代价的习惯
真实性	身份声明与真实角色的一致率；被评为“坏”的玩家确为坏人的比例；梅林是否隐瞒、坏人是否冒充	槽位含义由行为实测，不以名称为准
依据作用	各依据类型的使用分布；公开记录依据、身份视野声明与无依据三种判断对听者投票的影响	② 与 ③ 同时出现，需配合测试时关闭 ③ 或 J 配置
听者影响	替换单个槽位后听者投票与组队分布的 KL 变化	影响大不等于对己方有利，须结合收益
胜率贡献	训练时留一与测试时关闭同一槽位的胜率差，按阵营分别报告	两者之差对应适应能力，而不是该槽位的固有价值

另检查显式通道是否挤出隐式信号：在 S、M、F 下比较投票序列对隐藏身份的额外预测能力。如果开启显式通道后投票变得更不含信息，说明两种信道存在替代关系。

7 隐式信号的证据标准

公开行为与隐藏角色相关，只能证明行为包含可推断信息。要声称出现通信，还应证明接收者利用了这些行为；要进一步声称存在策略性信号，则需要发送者行为对接收者和收益的系统性作用。已有 emergent communication 研究说明，单看相关性或任务成绩容易产生误判。[6]

第一层 信息性：使用独立测试对局训练和评估简单 probe。比较“公共局面＋队伍与任务结果”与“再加入个人投票序列”的隐藏身份预测效果。数据按完整对局和训练种子划分，避免同一对局片段进入训练与测试。预测提升只记为额外信息，不直接标为隐式通信。

第二层 接收者使用：在固定 checkpoint 上回放同一接收者历史，将其他玩家的历史投票身份遮蔽，但保留总票数、提案结果与当前合法动作；从修改后的历史重新计算 GRU 状态，再比较接收者行动分布和后续收益。使用同长度占位作为 placebo，并以训练时见过遮蔽输入的辅助条件检验分布外影响。仅在推理时遮蔽导致性能下降，仍不足以单独证明通信。

第三层 策略性信号：优先分析不改变表决通过结果的非关键投票。在可合法实现、保持票数与通过结果一致的反事实投票组合之间比较接收者反应，并检查信息持有者是否系统性选择能影响队友的模式。进一步改变搭档或其响应策略，观察发送者策略是否随之调整。若只完成前两层，应使用“行为线索被利用”的结论，避免宣称已经证明发送者意图或形成完整通信协议。

重点分析 Percival 如何利用两名候选者的公开行为，以及 Morgana 是否形成稳定的混淆模式。稳健性检查包括角色与座位随机置换、未见过的角色分配和跨种子 cross-play。信号在不同种子间不兼容不等于群体内部没有信号。任务牌身份不公开，只能分析公开失败票数及其上下文。

最低完成标准：至少完成信息性 probe 和一个可解释的接收者干预，清楚报告证据层级。若第三层证据不足，把 RQ3 作为探索性观察与后续研究方向，仍保留完整的 RQ1、RQ2 贡献。

8 算力安排与自然语言扩展

本地与 HPC 分工

本地 RTX 5070 Ti Laptop 优先运行规则引擎、并行环境、小型 recurrent PPO 和统计分析；先计时测量 CPU 仿真与 GPU 更新各自占比，不能默认瓶颈一定在 GPU。正式开跑前记录实际显存、RAM、功耗限制和软件版本，本规划不假设已验证该设备的吞吐或训练时长。

建议为核心训练设置 40–60 GPU 小时的初始总预算上限，并用 pilot 修订 B：预计训练时间约为 配置数 × 种子数 × B × 每局平均训练耗时，另加调参与评估；核心层为 3 × 3，扩展层再加 3 × 3。若超预算，先降低单次训练量并保留重复种子；HPC 用于独立种子任务与扩展评估。核心项目不依赖持续取得 HPC 配额。

AvalonBench 代码库的 README 说明目前只支持五人局（Merlin、两名 Servants、Minion、Assassin），不含 Percival 与 Morgana，页面也未标明许可证。[10] 因此首选按已固定规则实现轻量状态机，AvalonBench 只作为规则与接口参考。课程仓库提供算法学习与实现参考，但不是现成 Avalon 环境。此阶段不要求完整复现 DeepRole 或 STRATEGIST。

语言层与自然语言扩展

分工：沿用 CICERO 把“说什么”和“怎么说”分开的思路。[12] RL 策略输出五槽结构化消息；语言层只做两件事：把结构化消息渲染成自然语言（模板即可，LLM 可选），以及在自然语言条件下把他人的发言解析回五槽结构。语言层不需要懂阿瓦隆策略，冻结的 API 模型或本地小模型即可胜任，无须专门训练。核心实验完全不依赖 LLM。

自然语言扩展采用一个冻结的本地 9B 模型，或一个固定版本的低成本 API 模型，分别扮演六个独立玩家。每名玩家使用隔离的上下文和记忆；只共享模型权重。发言以 JSON 输出五个槽位，关闭的槽位从输出格式中删除，另可附不超过 400 tokens 的自由文本，对应线下约 2 分钟的发言。NL-F、NL-M、NL-S 分别对应 F、M、S 的槽位开关，其他决策提示与预算保持一致。该实验验证语言代理中的方向是否类似，不能作为 MARL 策略已经学会自然语言的证据。

先用 20 局 pilot 检查规则理解、格式合法率、上下文长度、单局 token 和时延，再视预算每条件完成 100–300 局。所有游戏动作通过结构化接口选择；对非法输出使用固定重试与回退规则并报告频率。不能因模型表现不佳而丢弃整局。

本地 RTX 5070 Ti Laptop 为 12 GB 显存。9B 参数的原始权重在 FP16 下约需 18 GB，4-bit 下约需 4.5 GB，尚未包含量化元数据、KV cache 和运行开销。4-bit 量化推理是否可行须实测；能推理不代表同一设备可承担六角色长轨迹的端到端 LLM RL 训练。优先单模型串行或受限批处理，避免常驻六份权重。

API 成本按实际总输入与输出 token 分别乘以执行时价格计算。400 tokens 的发言上限会让上下文随对局增长，单局 token 须在 pilot 中实测。初始扩展预算可设为不超过 50 美元，超限则减少局数或转本地推理。本项目不需要先确定商业模型或付费方案。自由语言结果应单独展示，不能与结构化通信实验混合平均。

关于蒸馏开源模型：蒸馏不作为本课程交付，列为后续工作。蒸馏的前提是教师比学生更会玩，而现有通用 LLM 的阿瓦隆水平有限：AvalonBench 报告 ChatGPT 扮演好人、对阵规则 bot 坏人时胜率为 22.2%，规则 bot 好人为 38.2%。[4] 直接蒸馏 API 模型的发言会复制其弱点，而且多数商业 API 的服务条款限制用其输出训练其他模型，使用前须核对。更合理的两条路线：一是以本项目训练出的 RL 策略为教师做 policy distillation，[15] 把结构化观察和模板化发言转成文本，监督微调开源模型输出同样的五槽决策；二是用许可宽松的开源模型自博弈，只保留获胜方轨迹做筛选式行为克隆并迭代，这本身是一种基于结果的策略改进。12 GB 显存下，1–4B 模型的 LoRA 或 QLoRA 监督微调可行，9B 模型的 RL 微调不现实。

如果研究重点必须从第一天就是“自然语言 + 可训练 RL”，可另选冻结 LLM 编码器加小型 RL 决策头的混合路线，但需额外设计消息理解、缓存与训练接口。这会改变时间和算力预算，建议作为后续项目，而非本课程最低交付条件。

9 进度交付与失败处理

阶段	建议时间	验收内容
规则与试运行	10 月 20 日—26 日	六人环境、信息隔离与规则测试；五槽消息、开关、依据掩码与模板渲染的单元测试；随机和规则智能体可完整对局；确认课程题目
学习基线	10 月 27 日—11 月 2 日	Silent PPO 学习曲线；M 配置通过玩具检查与通信诊断；F 配置 pilot 测速；冻结正式配置
正式训练	11 月 3 日—16 日	核心层 S、M、F 各 3 种子；有余力启动留一配置；checkpoint 与完整配置存档；HPC 有条件并行
评估与机制	11 月 17 日—23 日	F → F、M → M、S → S、F → S 与测试时槽位消融；胜负分解、行为指标、RQ4 槽位分析、RQ3 初步干预
分析与报告	11 月 24 日—30 日	区间与交叉对战；完成论文图表和演示；有余力再做自然语言扩展

以上为六周实施安排，课程正式汇报时间与截止日期以教师确认的信息为准。第二阶段是关键检查点：若策略仍接近随机，或 M 配置的接收端影响接近零，应先排查信息、奖励、mask 与 credit assignment，再缩减模型、减少开启的槽位或缩小取值范围；不能直接把学习失败解释为“交流没有价值”。若到 11 月 9 日仍无法让通信被利用，则以 S 与 M 为主线，把通信学习失败作为一项结果报告，并结合文献讨论原因。

最低交付包括：含两名平民、Morgana、Assassin、Merlin 和 Percival 的六人环境；带开关的五槽消息协议；随机／规则基线及核心层 S、M、F 各至少三种子的学习记录；F → F、M → M、S → S、F → S 与测试时槽位消融；RQ1 胜率及分解图；RQ2 行为比较图；RQ4 槽位使用、真实性与听者影响分析；RQ3 信息性分析及一项干预；实验复现说明、技术报告和课堂演示。五种子、留一配置、完整 cross-play 和自然语言扩展按资源追加。

数据记录至少包含 game id、训练与评估 seed、通信配置及槽位开关、checkpoint、座位和角色映射、合法私有观察、提案、按槽位存储的消息元组及其模板渲染文本、公开投票、私有任务动作、公开任务结果、刺杀目标和最终胜负。私有真值日志与策略输入分开保存；同时保存配置、依赖版本、代码版本和分析脚本。

可接受的失败与边界：若通信未被成功学会，报告优化失败及已验证的行为，不把它推广为游戏机制结论；若胜率差异很小，报告区间和可排除的效果范围；若 RQ3 只有相关性，保留为探索结果。有限预算下训练的 self-play 策略不等于 Nash equilibrium，本文测量的是特定学习系统的经验表现。

最终成功标准是形成一个可复现、解释清楚的实验：说明哪些信息被允许、策略如何通过奖励学习、对照条件改变了什么、观察到的变化由哪些机制支持。结果不必证明沉默更偏向某一阵营，也不必强行发现隐式语言。

参考文献

[1] Serrino, J., Kleiman-Weiner, M., Parkes, D. C., & Tenenbaum, J. B. (2019). Finding Friend and Foe in Multi-Agent Games. NeurIPS 2019. 原文链接

[2] Nakamura, Y. (2017). Is it Percival time yet? A preliminary analysis of Avalon gameplay and strategy. SIGBOVIK 2017. 人类游戏的探索性分析。 原文链接

[3] Light, J., Cai, M., Chen, W., Wang, G., Chen, X., Cheng, W., Yue, Y., & Hu, Z. (2025). Strategist: Self-improvement of LLM Decision Making via Bi-Level Tree Search. ICLR 2025. 六人对话与非对话设置见附录 O。 原文链接

[4] Light, J., Cai, M., Shen, S., & Hu, Z. (2023). AvalonBench: Evaluating LLMs Playing the Game of Avalon. NeurIPS 2023 Foundation Models for Decision Making Workshop. 原文链接

[5] Lan, Y., Hu, Z., Wang, L., Wang, Y., Ye, D., Zhao, P., Lim, E.-P., Xiong, H., & Wang, H. (2024). LLM-Based Agent Society Investigation: Collaboration and Confrontation in Avalon Gameplay. EMNLP 2024, 128–145. 原文链接

[6] Lowe, R., Foerster, J., Boureau, Y.-L., Pineau, J., & Dauphin, Y. (2019). On the Pitfalls of Measuring Emergent Communication. AAMAS 2019. 原文链接

[7] Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A., & Wu, Y. (2022). The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games. NeurIPS 2022 Datasets and Benchmarks Track. 预印本始于 2021 年。 原文链接

[8] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347. 原文链接

[9] The Resistance: Avalon Rulebook. 游戏规则书，六人任务人数、表决、任务失败与刺杀规则；在线镜像。 原文链接

[10] Light, J. et al. Avalon-LLM. AvalonBench 与 STRATEGIST 代码库。引擎位于 avalonbench_dev，README 说明目前只支持五人局；如参考其代码，记录具体 commit 并核对复用许可。 原文链接

[11] Brandizzi, N., Grossi, D., & Iocchi, L. (2021). RLupus: Cooperation through Emergent Communication in The Werewolf Social Deduction Game. Intelligenza Artificiale, 15(2), 55–70. 原文链接

[12] Meta Fundamental AI Research Diplomacy Team (FAIR), Bakhtin, A., Brown, N., et al. (2022). Human-level play in the game of Diplomacy by combining language models with strategic reasoning. Science, 378(6624), 1067–1074. 原文链接

[13] Cao, K., Lazaridou, A., Lanctot, M., Leibo, J. Z., Tuyls, K., & Clark, S. (2018). Emergent Communication through Negotiation. ICLR 2018. 原文链接

[14] Jaques, N., Lazaridou, A., Hughes, E., Gulcehre, C., Ortega, P. A., Strouse, D. J., Leibo, J. Z., & de Freitas, N. (2019). Social Influence as Intrinsic Motivation for Multi-Agent Deep Reinforcement Learning. ICML 2019. 原文链接

[15] Rusu, A. A., Colmenarejo, S. G., Gulcehre, C., Desjardins, G., Kirkpatrick, J., Pascanu, R., Mnih, V., Kavukcuoglu, K., & Hadsell, R. (2016). Policy Distillation. ICLR 2016. 原文链接

[16] Foerster, J. N., Assael, Y. M., de Freitas, N., & Whiteson, S. (2016). Learning to Communicate with Deep Multi-Agent Reinforcement Learning. NeurIPS 2016. 原文链接

[C1] CS7329 Fall 2026. Current Topics Presentation and Paper (Graduate Students). 本地保存的课程项目要求，2 页。

[C2] Hahsler, M. Fall 2026 CS 7329 Reinforcement Learning 课程大纲；Introduction_to_Reinforcement_Learning 课程仓库本地备份。

本地 references 文件夹保存核心 10 篇：[1]–[3]、[5]–[8]、[11]、[13]、[16]，逐篇要点与阅读顺序见其中的 README.md。阅读重点依次为 DeepRole 的信息结构与无语言设定、STRATEGIST 的规则附录与附

录 O、PPO 与 MAPPO 的实现细节、RIAL 的消息训练方式、RLupus 的离散通信设计、Cao 等人关于 cheap talk 的结论，以及 Lowe 等人对通信测量的区分。